

Nama : Putri Agisnadiansyah

NIM : 20220801330

Judul TA : Perbandingan Algoritma XGBoost-SMOTE dan Random Forest SMOTE untuk Deteksi Fraud Transaksi Kartu Kredit Berdasarkan Standar POJK 2022

Analisa 5W1H

5W1H	Aanalisa
WHAT (Apa yang diteliti?)	Perbandingan XGBoost dan Random Forest dengan mengatasi <i>imbalanced dataset</i> menggunakan SMOTE berdasarkan regulasi kepatuhan terhadap POJK 2022 pada aspek keamanan data, auditability, traceability, serta transparansi model.
WHY (Mengapa penelitian ini penting?)	• Data transaksi kartu kredit sangat imbalanced, sehingga model cenderung bias. Maka itu algoritma yang dibandingkan menggunakan SMOTE untuk mengatasi bias tersebut. • Sistem deteksi fraud harus compliant dengan POJK dengan mengamankan data nasabah, audit trail, transparansi algoritma dan manajemen risiko TI.
WHO (Siapa saja pihak yang terlibat?)	Peneliti sebagai
WHEN (Kapan penelitian dilakukan?)	Penelitian berlangsung pada bulan September Tahun 2025 sampai dengan bulan April Tahun 2026 dengan mengikuti tahapan yang diawali dengan melakukan studi literatur dan menganalisa BRD sampai dengan melakukan analisis hasil analisisnya serta diikuti dengan melakukan dokumentasi Tugas Akhir pada penelitian.
WHERE (Dimana penelitian diterapkan?)	Lingkungan penelitian ini berada pada komputasi local dengan menggunakan dataset public yang disediakan pada Kaggle.
HOW (Bagaimana penelitian dilakukan?)	Dengan melakukan pengumpulan dan pemahaman data menggunakan dataset public pada Kaggle. Selanjutnya melakukan preprocessing data yang meliputi pembersihan nilai-nilai yang tidak valid dengan memastikan bahwa data dalam kondisi optimal sebelum digunakan pada model machine learning. Setelah itu, diterapkan Teknik SMOTE sebagai Langkah untuk menangani kelas yang ekstrem, sehingga menghasilkan sampel sintesis pada

	kelas fraud agar model dapat mengenali pola penipuan yang jarang muncul. Lalu, melakukan Pembangunan dan pelatihan model machine learning dengan berfokus pada algoritma utama yang memanfaatkan dataset hasil SMOTE. Sleanjutnya dilakukan dengan hyperparameter tuning menggunakan GridSearchCV dan k-fold Cross Validation. Setelah itu mengevaluasi kinerja model untuk menekankan pada metrik yang relevan. Lalu Melakukan analisis SHAP untuk memberikan penjelasan terukur terkait bagaimana model menghasilkan prediksi agar selaras terhadap regulasi POJK 2022 yang memiliki prinsip seperti transparansi, audit trail, dan explainability. Yang terakhir yaitu melakukan analisis kepatuhan (compliance assessment) terhadap standar POJK dengan menilai apakah proses oembangunan telah memenuhi aspek keamanan data, perlindungan data nasabah, transparansi model, manajemen risiko TI, dan jejak audit.
--	---

Analisa SWOT

S – Strengths (Kekuatan)

Kekuatan yang muncul dari WHAT, HOW, dan WHY dalam penelitian.

- Pendekatan Metodologis yang Komprehensif**
 Pipeline penelitian mencakup preprocessing, SMOTE, training, tuning, evaluasi, serta SHAP. Ini memberikan alur kerja yang **robust, terstruktur, dan dapat direplikasi**, sebuah keunggulan dibandingkan penelitian lain yang biasanya hanya membahas performa algoritmik.
- Fokus pada Algoritma Terbukti Kuat (XGBoost–SMOTE dan RF–SMOTE)**
 Berdasarkan SLR, XGBoost–SMOTE menunjukkan **F1-score tertinggi** dan performa stabil di berbagai tingkat ketidakseimbangan, sementara Random Forest–SMOTE memberikan baseline yang kuat. Kombinasi keduanya memperkuat validitas hasil perbandingan.
- Penanganan Data Imbalanced Secara Sistematis**
 Penggunaan SMOTE dan cross-validation mendukung peningkatan recall yang menjadi kunci deteksi fraud, sehingga meningkatkan efektivitas model pada konteks nyata.
- Integrasi Explainable AI (SHAP)**
 SHAP meningkatkan transparansi prediksi model dan mendukung kebutuhan auditabilitas—menjadi kekuatan utama dalam konteks regulatif POJK.

5. **Kesesuaian dengan Kerangka Regulasi POJK No. 11/POJK.03/2022**
Pipeline diselaraskan dengan aspek keamanan, manajemen risiko, dan explainability. Ini memberikan nilai tambah untuk implementasi industri.

W – Weaknesses (Kelemahan)

Kelemahan yang muncul dari HOW, WHY, WHERE, dan 5W1H secara keseluruhan.

1. **Ketergantungan pada Dataset Publik**
Dataset Kaggle tidak mewakili kompleksitas transaksi perbankan Indonesia sehingga model mungkin belum sepenuhnya menggambarkan kondisi riil industri.
2. **Potensi Overfitting akibat SMOTE**
SMOTE dapat menciptakan pola sintesis yang tidak selalu akurat dengan real-world fraud behavior, terutama ketika digunakan tanpa kombinasi undersampling atau teknik ensemble lain.
3. **Interpretasi Regulator Masih Berbasis Analisis Konseptual**
Kesesuaian dengan POJK dipetakan melalui analisis konseptual, bukan validasi industri, sehingga ada batas pada tingkat presisi compliance assessment.
4. **Komputasi Tinggi untuk Hyperparameter Tuning**
XGBoost dengan GridSearchCV berpotensi memakan waktu dan sumber daya besar, terutama pada perangkat komputasi terbatas.
5. **Model Tidak Menggunakan Data Sensitif atau Real-time**
Karena keterbatasan data, penelitian belum mencakup aspek real-time detection yang menjadi fokus utama deteksi fraud di industri perbankan.

O – Opportunities (Peluang)

Peluang yang muncul dari konteks WHO, WHY, WHERE, dan kebutuhan industri.

1. **Peluang Standardisasi Framework Deteksi Fraud sesuai POJK**
Dengan integrasi SHAP + evaluasi metrik + compliance mapping, penelitian ini bisa menjadi dasar **framework evaluasi ML untuk industri perbankan**.
2. **Penerapan pada Sistem Perbankan Nyata**
Penelitian dapat dikembangkan menjadi modul deteksi fraud early warning system, atau dipadukan dengan Security Operation Center (SOC) perbankan.
3. **Pengembangan Model ke Arah Federated Learning atau Blockchain**
Temuan SLR menunjukkan tren penggunaan federated learning + Random Forest-SMOTE atau blockchain untuk keamanan data. Ini membuka peluang penelitian lanjutan.
4. **Optimasi Algoritma untuk Real-time Detection**
Hasil awal dapat digunakan sebagai baseline untuk membuat versi ringan yang dapat berjalan real-time pada sistem transaksi bank.

5. Kolaborasi dengan Divisi Risk Management Perbankan

Model explainable memberikan potensi untuk didiskusikan dengan auditor internal, regulator, atau compliance officer.

T – Threats (Ancaman)

Ancaman yang berasal dari dinamika industri, teknologi fraud, dan aspek regulasi.

1. Evolusi Teknik Fraud yang Sangat Cepat

Pola fraud berubah dari waktu ke waktu, sehingga model yang dilatih pada dataset lama dapat menjadi tidak relevan (concept drift).

2. Risiko Pelanggaran Privasi dan Data Sensitif

Dalam implementasi nyata, penerapan ML memerlukan akses data nasabah yang masuk kategori data pribadi menurut UU PDP dan POJK – ini memiliki risiko hukum.

3. Regulatory Gap: POJK Belum Mengatur Teknis ML secara Detail

Meskipun POJK mengatur prinsip-prinsip TI, ia belum menjelaskan detail teknis ML seperti hyperparameter, XAI, atau interpretability standar. Ini bisa menimbulkan ketidakjelasan interpretasi.

4. Kompleksitas Integrasi ke Sistem Produksi Perbankan

Integrasi dengan core banking system, fraud monitoring system, atau payment gateway memerlukan pengujian dan sertifikasi tambahan yang kompleks.

5. Potensi False Positive Tinggi

Dalam industri perbankan, false positive dapat menimbulkan kerugian operasional, keluhan pelanggan, dan reputasi negatif—menjadi ancaman bagi implementasi buruk model.

Analisa Fishbone

1. People (Sumber Daya Manusia)

Akar permasalahan terkait kemampuan pengguna, analis, atau pengembang.

- **Keterbatasan keahlian dalam machine learning**

Banyak analis fraud atau staf perbankan belum familiar dengan XGBoost, Random Forest, balancing data, atau XAI (SHAP).

- **Kurangnya pemahaman terhadap POJK 11/POJK.03/2022**

Pengembangan model sering tidak mempertimbangkan mandat regulasi terkait keamanan data, audit trail, dan explainability.

2. Methods (Metode / Proses)

Permasalahan terkait pipeline, pendekatan ML, atau tahapan teknis.

- **Data imbalanced tidak ditangani dengan benar**

Tanpa SMOTE atau teknik balancing lain, model cenderung bias ke kelas normal.

- **Tidak ada hyperparameter tuning yang memadai**
Banyak model fraud detection di industri menggunakan default parameters → menurunkan akurasi.
- **Tidak menggunakan cross-validation yang memadai**
Model menjadi tidak stabil dan sulit direplikasi.
- **Kurangnya penerapan Explainable AI**
Tidak menggunakan SHAP atau metode interpretasi sehingga sulit memenuhi standar audit POJK.

3. Data (Kualitas & Lingkungan Data)

Akar masalah terkait dataset, kualitas data, ketidakseimbangan, noise, dan representasi pola fraud.

- **Ketidakseimbangan data yang ekstrem (fraud < 1%)**
Menjadi penyebab utama model gagal mendeteksi fraud.
- **Data tidak mencerminkan pola fraud terbaru**
Terjadi *concept drift* → pola fraud berubah cepat, data lama tidak representatif.
- **Noise tinggi dan outlier**
Tanpa preprocessing yang baik, model menjadi tidak stabil.

4. Technology / Machine (Teknologi, Tools, Infrastruktur)

Akar masalah terkait kemampuan komputasi, software, dan integrasi sistem ML.

- **Infrastruktur komputasi terbatas**
Model seperti XGBoost + GridSearchCV membutuhkan GPU/komputasi tinggi.
- **Sistem produksi bank belum siap untuk model ML kompleks**
Beberapa bank masih menggunakan rule-based system.
- **Keterbatasan integrasi real-time**
Model ML sulit diterapkan untuk transaksi real-time dengan latency rendah.
- **Kurangnya tools monitoring model**
Tidak ada sistem alert untuk drift, penurunan akurasi, atau false positive berlebih.

5. Environment (Lingkungan Operasional & Regulatif)

Akar masalah terkait kebijakan, regulasi, dan dinamika industri.

- **Regulasi AI di sektor finansial masih “prinsip umum”**
POJK belum menjelaskan teknis implementasi ML secara detail → memunculkan interpretasi yang berbeda-beda.

- **Peningkatan volume transaksi digital**
Membuat model lama tidak mampu menangani skala data.
- **Fraudster semakin canggih**
Taktik penipuan baru muncul sangat cepat → model perlu adaptif.
- **Batasan penggunaan data pribadi**
POJK membatasi jenis data yang boleh dipakai untuk training, sehingga beberapa fitur penting tidak dapat digunakan.

6. Materials (Dokumentasi, Standar, & Prosedur Kerja)

Akar masalah dari sisi dokumentasi teknis dan SOP.

- **Tidak ada prosedur standar untuk evaluasi model ML**
Evaluasi model sering tidak konsisten antar periode.
- **Dokumentasi pipeline tidak lengkap**
Menyulitkan audit trail sesuai POJK.
- **Tidak adanya standard operating procedures (SOP) untuk retraining model**
Model menjadi usang dan tidak relevan.
- **Minim pedoman integrasi XAI dalam audit regulasi**
Bank belum memiliki pedoman penggunaan SHAP atau XAI lain dalam konteks kepatuhan.