

Business Requirement Document (BRD)

Implementasi dan Analisis Hybrid Model XGBoost-SMOTE untuk Deteksi Penipuan Transaksi Kartu Kredit pada Data Tidak Seimbang

Disusun oleh : Putri Agisnadiansyah

NIM : 20220801330

1. Introduction

Dokumen *Business Requirement Document (BRD)* ini menjabarkan rancangan teknis dan kebutuhan sistem dalam penelitian implementasi dan analisis hybrid model XGBoost-SMOTE untuk mendeteksi penipuan transaksi kartu kredit pada data tidak seimbang (*imbalanced dataset*).

Penelitian ini mengutamakan aspek teknis berupa pembangunan pipeline machine learning end-to-end, mulai dari akuisisi data transaksi, pra-pemrosesan data (*data preprocessing*), penyeimbangan kelas menggunakan SMOTE (Synthetic Minority Oversampling Technique), pelatihan model XGBoost, evaluasi performa menggunakan berbagai metrik kuantitatif, hingga visualisasi hasil analisis dan interpretasi model dengan Explainable AI (XAI).

Desain pipeline dan pemilihan model dalam penelitian ini dirumuskan berdasarkan hasil tinjauan sistematis (SLR) yang menunjukkan kekuatan dan peluang model hybrid XGBoost-SMOTE dalam konteks deteksi penipuan kartu kredit.

Penerapan pendekatan hybrid ini didasarkan pada kebutuhan sistem deteksi penipuan modern yang harus:

1. Memproses data dalam volume besar dan berdimensi tinggi secara efisien.
2. Menangani distribusi data yang sangat tidak seimbang antara kelas *fraud* dan *non-fraud*.
3. Memberikan hasil deteksi yang tidak hanya akurat, tetapi juga dapat dijelaskan secara interpretatif.

Dari sisi implementasi teknis, sistem ini akan dikembangkan menggunakan bahasa Python, dengan pustaka utama seperti:

- **XGBoost** untuk pembelajaran berbasis *gradient boosting tree ensemble*.
- **Imbalanced-learn** untuk implementasi SMOTE.
- **Scikit-learn** untuk pra-pemrosesan dan evaluasi model.
- **SHAP** untuk analisis interpretabilitas model.
- **Matplotlib/Plotly** untuk visualisasi hasil eksperimen.

Pipeline utama yang diusulkan dalam penelitian ini terdiri dari tahapan berikut:

1. **Data Acquisition** – Pengumpulan dataset transaksi kartu kredit berlabel fraud dan non-fraud.

2. **Data Preprocessing** – Pembersihan data, normalisasi, encoding fitur kategorikal, dan reduksi dimensi jika diperlukan.
3. **Data Balancing (SMOTE)** – Penambahan sampel sintetis pada kelas minoritas untuk mengatasi ketidakseimbangan kelas.
4. **Model Training (XGBoost)** – Pelatihan model dengan optimasi parameter menggunakan *grid search* atau *Bayesian optimization*.
5. **Model Evaluation** – Pengujian model dengan metrik kuantitatif (Precision, Recall, F1-Score, AUC-ROC).
6. **Model Interpretation** – Analisis kontribusi fitur terhadap hasil prediksi menggunakan SHAP.
7. **Reporting & Visualization** – Visualisasi hasil evaluasi dan pembuatan laporan performa model.

Pendekatan yang disusun menitikberatkan pada optimalisasi performa teknis sistem serta keandalan metode dalam mendeteksi transaksi penipuan secara efisien pada kondisi data yang kompleks dan tidak seimbang.

2. Latar Belakang dan Justifikasi Penelitian

2.1 Konteks Penelitian

Transaksi kartu kredit merupakan salah satu aktivitas finansial dengan volume data sangat tinggi dan tingkat risiko penipuan yang signifikan. Sistem deteksi tradisional berbasis aturan (*rule-based system*) memiliki keterbatasan dalam mengenali pola penipuan baru karena tidak mampu beradaptasi terhadap perubahan pola perilaku pengguna.

Ketidakseimbangan data (di mana proporsi transaksi normal bisa mencapai lebih dari 99%) menjadi hambatan utama bagi model pembelajaran mesin. Model sering kali mengabaikan kelas minoritas (penipuan), menghasilkan false negative yang tinggi. Dalam konteks finansial, satu kesalahan deteksi saja dapat menimbulkan kerugian besar.

Untuk mengatasi hal tersebut, penelitian ini mengusulkan kombinasi dua pendekatan utama:

1. **SMOTE (Synthetic Minority Oversampling Technique)** – untuk menyeimbangkan data dengan menambahkan sampel sintetis berbasis *k-nearest neighbors* pada kelas minoritas.
2. **XGBoost (Extreme Gradient Boosting)** – algoritma boosting yang mampu mempelajari pola non-linear kompleks serta memiliki performa tinggi pada data tabular dengan *imbalanced distribution*.

Secara teknis, integrasi antara SMOTE dan XGBoost akan diimplementasikan dalam pipeline terstruktur dengan skema pelatihan dan pengujian terpisah (*train-test split*). Selain itu, penelitian ini akan menggunakan *cross-validation* untuk menghindari *overfitting* serta menguji stabilitas model pada berbagai subset data.

2.2 Permasalahan Teknis Utama

1. Distribusi data transaksi kartu kredit sangat tidak seimbang (rasio fraud < 0,5%).

2. Model konvensional mengalami *bias* terhadap kelas mayoritas, mengabaikan transaksi penipuan.
3. Proses pra-pemrosesan data (missing value, outlier, encoding) belum distandarkan dengan baik.
4. Parameter model (*learning rate*, *max_depth*, *n_estimators*) sering kali tidak dioptimalkan, menyebabkan performa sub-optimal.
5. Kurangnya sistem monitoring dan interpretasi hasil model untuk analisis lebih lanjut.

2.3 Solusi Teknis yang Diusulkan

Solusi penelitian ini bersifat end-to-end machine learning system yang terintegrasi, terdiri atas beberapa modul utama:

Tahapan Teknis	Deskripsi Implementasi
Preprocessing Module	Melakukan pembersihan data, transformasi fitur numerik & kategorikal, serta deteksi <i>outlier</i> .
Balancing Module (SMOTE Engine)	Menghasilkan data sintetis pada kelas fraud dengan teknik <i>k-nearest neighbor interpolation</i> .
Model Training Module (XGBoost)	Melatih model dengan skema <i>cross-validation</i> dan <i>hyperparameter tuning</i> berbasis <i>GridSearchCV</i> atau <i>Optuna</i> .
Evaluation Module	Menghitung <i>Precision</i> , <i>Recall</i> , <i>F1-Score</i> , <i>AUC-ROC</i> , serta <i>confusion matrix</i> .
Interpretation Module (SHAP)	Menjelaskan kontribusi tiap fitur terhadap probabilitas transaksi dikategorikan fraud.
Visualization & Reporting Module	Menampilkan grafik <i>ROC curve</i> , <i>feature importance</i> , dan laporan evaluasi model.

Pipeline ini memastikan proses analisis dilakukan secara sistematis, terukur, dan dapat direproduksi.

2.4 Keunggulan Teknis Penelitian

- **Stabilitas dan akurasi tinggi:** kombinasi SMOTE-XGBoost mengurangi bias kelas mayoritas.
- **Kinerja efisien:** XGBoost mendukung paralelisasi di GPU, mempercepat waktu pelatihan.
- **Analisis interpretatif:** SHAP memberikan transparansi terhadap keputusan model.
- **Scalability:** pipeline dapat diimplementasikan di lingkungan *cloud computing* untuk dataset berskala besar.

- **Reproduksibilitas eksperimen:** seluruh kode, parameter, dan hasil evaluasi didokumentasikan dengan baik.

3. Tujuan Penelitian

3.1 Tujuan Utama

Tujuan utama penelitian ini adalah mengimplementasikan dan menganalisis model hybrid XGBoost-SMOTE untuk meningkatkan performa sistem deteksi penipuan transaksi kartu kredit pada data yang tidak seimbang. Fokus teknis penelitian mencakup:

1. Perancangan pipeline sistem deteksi penipuan berbasis Machine Learning

Mengembangkan pipeline *end-to-end* yang terdiri atas tahapan pra-pemrosesan, penyeimbangan data (SMOTE), pelatihan model (XGBoost), evaluasi, dan interpretasi hasil. Pipeline ini akan diimplementasikan dalam lingkungan Python menggunakan pustaka *Scikit-learn*, *Imbalanced-learn*, *XGBoost*, dan *SHAP*.

2. Optimasi Hyperparameter Model XGBoost

Melakukan *hyperparameter tuning* terhadap variabel penting seperti:

- `learning_rate`
- `max_depth`
- `n_estimators`
- `subsample`
- `colsample_bytree`

Proses optimasi dilakukan dengan metode *Grid Search* dan *Cross Validation* ($k=5$) untuk memperoleh parameter terbaik yang memaksimalkan *F1-Score* dan *AUC-ROC*.

3. Integrasi Teknik SMOTE pada Tahapan Pra-Pemrosesan Data

Mengintegrasikan algoritma SMOTE (Synthetic Minority Oversampling Technique) untuk menambah sampel sintetis pada kelas minoritas (fraud) dengan mekanisme *k-nearest neighbor interpolation*. Implementasi dilakukan menggunakan pustaka `imblearn.over_sampling`. SMOTE, yang dikonfigurasi dengan parameter `k_neighbors = 5` serta `random_state` konstan untuk memastikan hasil replikasi eksperimen.

4. Evaluasi dan Validasi Performa Model

Mengevaluasi hasil prediksi menggunakan metrik performa berikut:

- **Precision (Positive Predictive Value)** – mengukur proporsi deteksi fraud yang benar.
- **Recall (Sensitivity)** – mengukur kemampuan model dalam menemukan semua transaksi fraud.
- **F1-Score** – menggabungkan precision dan recall secara harmonis.
- **AUC-ROC** – menilai kemampuan model dalam membedakan antara kelas fraud dan non-fraud. Selain itu, dilakukan validasi menggunakan *hold-out set* dan *cross-validation* untuk menghindari *overfitting*.

5. Analisis Interpretabilitas Model Menggunakan Explainable AI (XAI)

Menggunakan SHAP (SHapley Additive exPlanations) untuk mengidentifikasi fitur-fitur yang paling berpengaruh terhadap keputusan model. Tahapan ini mencakup visualisasi *feature importance*, analisis *SHAP summary plot*, dan *force plot* untuk transaksi individu guna memahami alasan klasifikasi model.

3.2 Tujuan Tambahan

Selain implementasi dan evaluasi teknis utama, penelitian ini juga memiliki tujuan tambahan berikut:

1. **Mengembangkan framework eksperimental yang dapat direproduksi**, di mana seluruh tahapan pipeline, parameter, dan hasil evaluasi terdokumentasi dan dapat dijalankan ulang secara konsisten.
2. **Menyediakan analisis komparatif kuantitatif** antara model baseline (tanpa SMOTE) dan model hybrid (dengan SMOTE), untuk menunjukkan peningkatan signifikan dalam metrik evaluasi.
3. **Menyusun dokumentasi teknis berbasis hasil eksperimen**, termasuk konfigurasi *hardware/software environment*, parameter pelatihan, dan diagram alur sistem untuk mendukung replikasi hasil penelitian.

3.3 Indikator Keberhasilan Teknis

Bagian ini mendefinisikan parameter kuantitatif yang digunakan untuk menilai keberhasilan sistem dari sisi performa teknis dan kualitas model.

Kategori	Metrik Teknis	Kriteria Evaluasi dan Target Minimal
Kinerja Model	F1-Score	≥ 0.95 — menunjukkan keseimbangan precision dan recall pada dataset tidak seimbang.
	AUC-ROC	≥ 0.99 — menandakan kemampuan model membedakan kelas fraud dan non-fraud dengan baik.
	Precision (Positive Predictive Value)	≥ 0.98 — memastikan sedikit <i>false positive</i> pada deteksi fraud.
	Recall (Sensitivity)	≥ 0.97 — memastikan sebagian besar transaksi penipuan terdeteksi.
Efisiensi Sistem	Training Time	≤ 6 jam pada dataset ≥ 100.000 baris dengan GPU aktif.
	Inference Time per Record	≤ 0.5 detik untuk transaksi baru.

Kategori	Metrik Teknis	Kriteria Evaluasi dan Target Minimal
Stabilitas & Validitas	Cross-Validation Score Consistency	Variasi skor antar fold $\leq 2\%$.
	Reproducibility Rate	$\geq 95\%$ hasil eksperimen dapat diulang dengan konfigurasi sama.
Analisis Interpretabilitas	SHAP Feature Explanation Coverage	Minimal 10 fitur dominan terjelaskan dengan nilai SHAP > 0.05 .
Output Sistem	Dashboard dan Laporan Teknis	Berisi metrik utama, visualisasi ROC curve, confusion matrix, dan analisis SHAP dalam format terstruktur (.pdf atau .xlsx).

4. Ruang Lingkup

Ruang lingkup penelitian ini didefinisikan untuk memastikan bahwa fokus kegiatan pengembangan dan analisis tetap berada pada aspek teknis dari sistem deteksi penipuan berbasis model hybrid XGBoost-SMOTE. Ruang lingkup dibagi menjadi dua bagian utama: *In-Scope* (termasuk dalam penelitian) dan *Out-of-Scope* (tidak termasuk dalam cakupan penelitian).

4.1 Termasuk (In-Scope)

Aspek Teknis	Deskripsi Kegiatan dan Implementasi
1. Akuisisi Dataset	Pengumpulan dataset transaksi kartu kredit dari sumber publik seperti <i>Kaggle Kredit Card Fraud Dataset</i> atau dataset institusional dengan struktur serupa. Dataset harus mengandung label biner: <i>fraud</i> (1) dan <i>non-fraud</i> (0).
2. Data Preprocessing	Implementasi tahapan teknis: <i>data cleaning</i> , penanganan <i>missing values</i> , <i>outlier detection</i> , <i>scaling</i> (menggunakan StandardScaler), dan <i>feature encoding</i> .
3. Balancing dengan SMOTE	Penerapan algoritma SMOTE untuk melakukan oversampling pada kelas minoritas (fraud). Parameter dasar: <code>k_neighbors=5</code> , <code>sampling_strategy='auto'</code> .
4. Training Model XGBoost	Pelatihan model XGBoost pada dataset hasil SMOTE dengan optimasi parameter. Dijalankan menggunakan GPU dengan pustaka xgboost versi terbaru.
5. Hyperparameter Optimization	Penggunaan <i>GridSearchCV</i> atau <i>Optuna</i> untuk mencari konfigurasi terbaik dari parameter: <code>learning_rate</code> , <code>max_depth</code> , <code>n_estimators</code> , dan <code>gamma</code> .

Aspek Teknis	Deskripsi Kegiatan dan Implementasi
6. Evaluasi Kinerja Model	Pengujian hasil model terhadap metrik: Accuracy, Precision, Recall, F1-Score, AUC-ROC, serta <i>confusion matrix</i> . Evaluasi dilakukan pada <i>hold-out test set</i> .
7. Interpretabilitas Model (XAI)	Penerapan SHAP untuk menghitung kontribusi setiap fitur terhadap prediksi fraud, menghasilkan <i>SHAP summary plot</i> dan <i>feature importance chart</i> .
8. Visualisasi dan Reporting	Penyusunan <i>dashboard</i> hasil evaluasi model menggunakan <i>Matplotlib</i> atau <i>Plotly</i> , serta pembuatan laporan teknis berbasis hasil analisis.
9. Eksperimen Reproduksi	Pengujian ulang pipeline pada subset data berbeda untuk menilai konsistensi performa model.

4.2 Tidak Termasuk (Out-of-Scope)

Aspek	Keterangan
1. Integrasi ke Sistem Produksi	Implementasi ke dalam <i>real-time fraud detection system</i> bank tidak termasuk dalam lingkup penelitian.
2. Deteksi Jenis Penipuan Lain	Penelitian tidak mencakup penipuan non-transaksional seperti <i>identity theft</i> atau <i>phishing</i> .
3. Penggunaan Data Rahasia	Dataset internal perbankan yang bersifat rahasia tidak digunakan; seluruh data bersifat anonim dan publik.
4. Optimasi Infrastruktur Cloud	Eksperimen skala besar berbasis <i>distributed computing</i> tidak dilakukan; sistem diuji secara lokal atau di GPU tunggal.
5. Aspek Keamanan Implementasi	Pengujian <i>cybersecurity</i> terhadap sistem deteksi tidak menjadi bagian dari penelitian ini.

5. Stakeholders dan Pengguna

Stakeholder / Pengguna	Peran dan Tanggung Jawab Teknis
1. Peneliti / Mahasiswa (Data Scientist)	Bertanggung jawab terhadap keseluruhan pipeline pengembangan: <i>data preprocessing</i> , <i>SMOTE balancing</i> , <i>model training</i> , <i>hyperparameter tuning</i> , dan evaluasi metrik performa.
2. Dosen Pembimbing / Reviewer Akademik	Menilai validitas metodologi, desain eksperimen, serta keabsahan hasil analisis statistik dan interpretasi model.
3. Divisi Risk Management (Simulatif)	Bertindak sebagai pihak pengguna akhir hasil model untuk menganalisis risiko transaksi dan potensi fraud dalam studi kasus simulatif.

Stakeholder / Pengguna	Peran dan Tanggung Jawab Teknis
4. Tim IT / Analis Sistem	Melakukan pengujian replikasi pipeline, memverifikasi dokumentasi, serta memastikan kompatibilitas sistem terhadap lingkungan komputasi GPU atau cloud.
5. Manajemen Akademik / Penanggung Jawab Proyek	Mengawasi keseluruhan pelaksanaan penelitian dan memvalidasi bahwa hasil memenuhi target teknis dan ilmiah.
6. Komunitas Riset / Akademisi Eksternal	Pihak yang dapat menggunakan framework hasil penelitian sebagai acuan eksperimen pada dataset finansial lain.

6. Persyaratan Fungsional (Functional Requirements)

Persyaratan fungsional berikut mendeskripsikan komponen dan fungsi utama yang harus diimplementasikan dalam sistem deteksi penipuan berbasis hybrid XGBoost-SMOTE. Setiap fungsi dijelaskan dari sisi teknis implementasi, algoritma, dan output yang dihasilkan.

Kode	Persyaratan Fungsional	Deskripsi Teknis Implementasi
FR-1	Data Acquisition & Import	Sistem harus dapat membaca dataset transaksi kartu kredit dalam format .csv atau .parquet. Implementasi menggunakan <code>pandas.read_csv()</code> dengan verifikasi <i>data types</i> , <i>missing values</i> , dan <i>class imbalance ratio</i> .
FR-2	Data Preprocessing Module	Melakukan tahapan <i>data cleaning</i> (menghapus duplikasi, menangani missing values), <i>feature encoding</i> untuk variabel kategorikal menggunakan LabelEncoder atau OneHotEncoder, serta <i>feature scaling</i> menggunakan StandardScaler.
FR-3	Data Balancing (SMOTE Engine)	Menerapkan Synthetic Minority Oversampling Technique (SMOTE) dari pustaka <code>imblearn</code> . Parameter utama: <code>sampling_strategy='auto'</code> , <code>k_neighbors=5</code> . Hasil berupa dataset seimbang yang siap dilatih.
FR-4	Dataset Splitting	Dataset dibagi menjadi <i>train set</i> dan <i>test set</i> dengan rasio 80:20. Pembagian dilakukan secara acak namun terkontrol menggunakan <code>train_test_split(random_state=42)</code> .
FR-5	Model Training (XGBoost)	Melatih model <code>XGBoostClassifier</code> dari pustaka <code>xgboost</code> . Parameter awal meliputi <code>learning_rate=0.1</code> , <code>max_depth=6</code> , <code>n_estimators=300</code> , <code>subsample=0.8</code> , dan <code>colsample_bytree=0.8</code> . Implementasi menggunakan GPU dengan opsi <code>tree_method='gpu_hist'</code> .

Kode	Persyaratan Fungsional	Deskripsi Teknis Implementasi
FR-6	Hyperparameter Optimization	Mengoptimalkan parameter model menggunakan GridSearchCV atau pustaka Optuna untuk menemukan kombinasi parameter terbaik. Proses dilakukan dengan <i>5-fold cross-validation</i> untuk menjaga generalisasi.
FR-7	Model Evaluation	Menghitung metrik kinerja: Accuracy, Precision, Recall, F1-Score, AUC-ROC, serta <i>Confusion Matrix</i> menggunakan pustaka sklearn.metrics. Hasil disimpan dalam format tabel dan visualisasi grafik.
FR-8	Explainable AI (SHAP Analysis)	Mengimplementasikan SHAP untuk menjelaskan kontribusi setiap fitur terhadap prediksi. Menghasilkan visualisasi <i>summary plot</i> , <i>force plot</i> , dan <i>feature importance</i> .
FR-9	Performance Visualization Dashboard	Membuat dashboard sederhana untuk menampilkan hasil evaluasi model: grafik AUC, distribusi kelas sebelum dan sesudah SMOTE, serta metrik performa. Dapat dibangun menggunakan Plotly Dash atau Streamlit.
FR-10	Model Persistence & Reporting	Menyimpan model terbaik dalam format .pkl menggunakan joblib.dump() dan menghasilkan laporan performa otomatis dalam format .pdf atau .xlsx.

Catatan Teknis

- Seluruh pipeline dieksekusi dalam *Python Jupyter Notebook* atau *Python script* modular.
- Setiap modul (preprocessing, SMOTE, training, evaluation, SHAP) disusun dalam fungsi terpisah untuk menjaga modularitas.
- Setiap eksperimen disertai *seed* tetap (`random_state=42`) untuk menjamin reproduisibilitas hasil.

7. Persyaratan Non-Fungsional (Non-Functional Requirements)

Bagian ini menetapkan batasan teknis dan standar kinerja yang harus dipenuhi oleh sistem untuk memastikan efisiensi, kestabilan, dan keandalan pipeline yang dikembangkan.

Kode	Persyaratan Non-Fungsional	Deskripsi Teknis dan Kriteria Kinerja
NFR-1	Efisiensi Komputasi	Proses pelatihan model harus dapat diselesaikan dalam waktu ≤ 6 jam untuk dataset berukuran ≥ 100.000 baris. Pemrosesan dijalankan pada GPU dengan CUDA support atau cloud environment seperti Google Colab/Vertex AI.

Kode	Persyaratan Non-Fungsional	Deskripsi Teknis dan Kriteria Kinerja
NFR-2	Reproduksibilitas Pipeline	Semua langkah pipeline harus terdokumentasi dan dapat dijalankan ulang dengan hasil yang konsisten. Versi pustaka Python dan seed eksperimen wajib dicatat dalam file requirements.txt.
NFR-3	Kinerja Inferensi (Latency)	Sistem harus mampu memberikan hasil prediksi fraud/non-fraud dalam waktu ≤ 500 milidetik per transaksi baru. Pengujian dilakukan menggunakan <code>time.perf_counter()</code> pada 1000 sampel acak.
NFR-4	Akurasi & Stabilitas Model	Model harus mempertahankan F1-Score ≥ 0.95 dan AUC-ROC ≥ 0.99 secara konsisten di lima kali uji <i>cross-validation</i> .
NFR-5	Ketersediaan & Ketahanan Sistem	Sistem (dashboard dan pipeline) harus memiliki <i>uptime</i> minimal 99% selama pengujian. File model yang disimpan harus terlindung dari korupsi atau kehilangan data.
NFR-6	Interpretabilitas & Transparansi	Analisis SHAP harus menyertakan minimal 10 fitur dengan nilai <i>importance</i> tertinggi, serta hasil interpretasi disajikan dalam laporan akhir.
NFR-7	Kepatuhan Regulasi Data	Dataset harus dianonimkan sepenuhnya dan tidak mengandung informasi pribadi (<i>Personally Identifiable Information – PII</i>). Penelitian mengikuti pedoman keamanan data sesuai regulasi OJK dan GDPR.
NFR-8	Portabilitas Sistem	Pipeline dapat dijalankan baik pada <i>local environment</i> (Python 3.10+) maupun <i>cloud-based runtime</i> tanpa modifikasi signifikan.
NFR-9	Scalability (Skalabilitas)	Sistem dirancang modular sehingga memungkinkan integrasi tambahan seperti model ensemble atau adaptasi algoritma ADASYN pada tahap pengembangan berikutnya.

8. Use Case Penelitian

8.1 Deskripsi Umum


Bagian ini menjelaskan interaksi antaraktor yang terlibat dalam sistem deteksi penipuan berbasis Hybrid Model XGBoost-SMOTE. Use case ini berfokus pada alur teknis pemrosesan data, pelatihan model, evaluasi, interpretasi hasil, dan pelaporan performa.

Aktor utama meliputi:

- **Data Scientist / Peneliti** – Bertanggung jawab terhadap pra-pemrosesan data, pelatihan model, evaluasi, dan analisis interpretabilitas.

- **Risk Management (Simulatif)** – Menggunakan hasil laporan model untuk menganalisis potensi transaksi penipuan.
- **Manajemen Akademik / Reviewer** – Mengevaluasi hasil eksperimen dan memastikan metodologi sesuai standar ilmiah.


8.2 Use Case Diagram



Penjelasan Teknis Diagram:

1. **Data Scientist** menjalankan pipeline dari tahap data preprocessing hingga analisis interpretabilitas.
2. **Risk Management** mengakses hasil evaluasi dari dashboard performa untuk menilai efektivitas deteksi fraud.
3. **Reviewer Akademik** memverifikasi hasil eksperimen dan laporan akhir untuk tujuan akademik dan replikasi riset.

8.3 Arsitektur Teknis Sistem



9. Analisis Risiko dan Mitigasi

Bagian ini membahas potensi risiko teknis yang dapat muncul selama proses penelitian dan strategi mitigasi yang diusulkan untuk menjaga kualitas hasil eksperimen.

No	Risiko Teknis	Dampak	Probabilitas	Strategi Mitigasi Teknis
R1	Ketidakseimbangan data tidak sepenuhnya teratasi oleh SMOTE	Menurunkan recall model terhadap kelas fraud	Sedang	Kombinasikan SMOTE dengan metode <i>undersampling</i> atau gunakan varian SMOTEENN/ADASYN.
R2	Overfitting pada model XGBoost	Model memiliki performa tinggi pada data latih tetapi buruk pada data uji	Tinggi	Gunakan <i>cross-validation</i> , regularisasi (λ , α), dan <i>early stopping</i> .
R3	Kinerja GPU tidak optimal selama pelatihan	Waktu pelatihan melebihi target efisiensi	Sedang	Gunakan <code>tree_method='gpu_hist'</code> dan optimalkan batch data; pastikan driver CUDA sesuai versi pustaka XGBoost.
R4	Model tidak interpretatif (black-box)	Sulit menjelaskan hasil klasifikasi	Tinggi	Gunakan <i>Explainable AI</i> (SHAP) untuk analisis <i>feature contribution</i> dan <i>summary plot</i> .
R5	Ketidakstabilan hasil eksperimen antar-run	Sulit mengulangi hasil evaluasi	Sedang	Gunakan <code>random_state</code> tetap di semua tahapan pipeline dan dokumentasikan konfigurasi environment.
R6	Concept Drift pada data baru	Model kehilangan akurasi setelah jangka waktu tertentu	Sedang	Lakukan retraining model secara periodik dengan data terkini dan monitor metrik kinerja dari waktu ke waktu.
R7	Kualitas data rendah (noise tinggi)	Fitur penting sulit terdeteksi	Sedang	Terapkan <i>outlier detection</i> dan filtering sebelum tahap SMOTE.
R8	Interpretasi SHAP membutuhkan sumber daya besar	Proses analisis interpretabilitas lambat	Rendah	Gunakan <i>sampling subset</i> data untuk perhitungan SHAP dan caching hasil perhitungan.

10. Asumsi Penelitian

Bagian ini menjelaskan asumsi-asumsi teknis dan metodologis yang menjadi dasar pelaksanaan penelitian, termasuk ketersediaan data, sumber daya komputasi, serta kondisi eksperimental yang mendukung keberhasilan implementasi sistem hybrid XGBoost-SMOTE.

No	Asumsi Teknis / Metodologis	Penjelasan dan Relevansi
A1	Ketersediaan Dataset Representatif	Dataset transaksi kartu kredit yang digunakan bersifat publik (misal: <i>Credit Card Fraud Detection Dataset – Kaggle</i>), memiliki atribut numerik dan label biner (<i>fraud / non-fraud</i>), serta cukup besar (> 200.000 record) untuk melatih model XGBoost secara efektif.
A2	Distribusi Data Mewakili Kondisi Nyata	Rasio ketidakseimbangan antara kelas normal dan fraud diasumsikan serupa dengan kondisi transaksi aktual, yaitu sekitar 99.8% : 0.2%.
A3	Kualitas Data Cukup Baik	Dataset telah melalui tahap pembersihan dasar (<i>data cleaning</i>), tidak memiliki nilai kosong yang signifikan, dan tidak terdapat kesalahan label yang dapat menyebabkan bias pelatihan.
A4	Ketersediaan Sumber Daya Komputasi GPU	Penelitian diasumsikan dijalankan di lingkungan dengan dukungan GPU (misalnya: Google Colab Pro, AWS, atau sistem lokal dengan $CUDA \geq 11.0$). Hal ini penting agar proses pelatihan XGBoost dapat berjalan optimal.
A5	Keberfungsian Pustaka dan Lingkungan Pemrograman	Versi pustaka Python yang digunakan telah stabil dan kompatibel satu sama lain, seperti: $xgboost \geq 2.0.0$, $scikit-learn \geq 1.3$, $imbalanced-learn \geq 0.12$, dan $shap \geq 0.44$.
A6	Model Berbasis Supervised Learning	Diasumsikan bahwa seluruh data pelatihan memiliki label yang akurat sehingga algoritma supervised seperti XGBoost dapat belajar secara efektif dari pola data historis.
A7	Konsistensi Random State dan Seed	Seluruh eksperimen menggunakan <i>fixed random seed</i> ($random_state=42$) untuk menjamin reproduktibilitas hasil dan mencegah variasi acak pada hasil pelatihan.
A8	Keamanan dan Etika Data	Seluruh data yang digunakan bersifat anonim dan bebas dari <i>Personally Identifiable Information (PII)</i> sesuai standar etika penelitian dan regulasi OJK.
A9	Tidak Terjadi Concept Drift Signifikan Selama Eksperimen	Selama periode penelitian, diasumsikan pola data tidak berubah secara drastis, sehingga hasil model tetap valid untuk interpretasi performa.

No	Asumsi Teknis / Metodologis	Penjelasan dan Relevansi
A10	Akses ke Infrastruktur Analisis	Diasumsikan peneliti memiliki akses terhadap <i>software environment</i> dan pustaka visualisasi (Matplotlib/Plotly) untuk mendukung pembuatan laporan analisis.

11. Glosarium

Bagian ini memuat daftar istilah teknis yang digunakan dalam dokumen BRD untuk memastikan konsistensi terminologi dan pemahaman bagi pembaca akademik maupun teknis.

Istilah	Definisi Teknis
XGBoost (Extreme Gradient Boosting)	Algoritma pembelajaran mesin berbasis <i>ensemble gradient boosting</i> yang menggabungkan beberapa pohon keputusan untuk meningkatkan akurasi prediksi. Dikenal efisien dan mendukung GPU acceleration.
SMOTE (Synthetic Minority Oversampling Technique)	Metode <i>oversampling</i> yang menciptakan data sintesis pada kelas minoritas untuk menyeimbangkan distribusi dataset tidak seimbang.
Imbalanced Data	Kondisi ketika satu kelas (misalnya non-fraud) memiliki jumlah data jauh lebih besar dibandingkan kelas lainnya (fraud).
Precision	Rasio antara jumlah prediksi fraud yang benar dibandingkan seluruh prediksi fraud oleh model.
Recall (Sensitivity)	Rasio antara jumlah transaksi fraud yang berhasil dideteksi dibandingkan total transaksi fraud sebenarnya.
F1-Score	Harmonik rata-rata antara precision dan recall, menggambarkan keseimbangan antara keduanya.
AUC-ROC (Area Under Curve – Receiver Operating Characteristic)	Ukuran kinerja model klasifikasi dalam membedakan kelas positif (fraud) dan negatif (non-fraud).
SHAP (SHapley Additive exPlanations)	Algoritma <i>Explainable AI (XAI)</i> untuk mengukur kontribusi setiap fitur terhadap hasil prediksi model.
Cross-Validation	Teknik evaluasi performa model dengan membagi dataset ke dalam beberapa lipatan (<i>folds</i>) agar hasil penilaian lebih stabil dan tidak bergantung pada satu subset data.

Istilah	Definisi Teknis
Hyperparameter Tuning	Proses mencari kombinasi nilai parameter terbaik (seperti <i>max_depth</i> , <i>learning_rate</i> , <i>n_estimators</i>) yang menghasilkan performa optimal untuk model.
Confusion Matrix	Matriks evaluasi yang menggambarkan jumlah prediksi benar dan salah untuk setiap kelas dalam klasifikasi.
Explainable AI (XAI)	Bidang kecerdasan buatan yang berfokus pada pengembangan model yang dapat dijelaskan, agar hasil prediksi dapat dipahami oleh manusia.
Outlier Detection	Proses mendeteksi nilai data yang menyimpang jauh dari distribusi umum dan berpotensi mengganggu pelatihan model.
Concept Drift	Perubahan distribusi data dari waktu ke waktu yang menyebabkan model kehilangan kemampuan generalisasi.
Pipeline Machine Learning	Rangkaian langkah otomatis yang terdiri dari preprocessing, balancing, training, evaluasi, hingga interpretasi model.
Feature Importance	Ukuran kontribusi relatif setiap fitur terhadap hasil prediksi model.
GPU Acceleration	Pemanfaatan unit pemrosesan grafis (GPU) untuk mempercepat perhitungan paralel dalam proses pelatihan model besar.
Reproducibility	Kemampuan untuk mengulangi eksperimen dengan hasil yang konsisten menggunakan konfigurasi, data, dan parameter yang sama.